Dominando BigQuery: De la Carga de Datos al Análisis Avanzado

¡Bienvenidos a este módulo de BigQuery! En esta presentación, exploraremos las capacidades de esta potente herramienta de Google Cloud para el procesamiento y análisis de grandes volúmenes de datos. BigQuery no es solo una base de datos; es un motor de análisis completamente gestionado que permite a las empresas y a los analistas de datos transformar información bruta en conocimiento accionable, todo ello a una escala que pocas plataformas pueden igualar.

En las próximas tarjetas, profundizaremos en los aspectos fundamentales para trabajar con BigQuery, desde la preparación y carga eficiente de tus conjuntos de datos hasta la ejecución de consultas complejas y la optimización de tus procesos analíticos. Nuestro objetivo es proporcionarte una guía clara y práctica que te permita explotar al máximo el potencial de BigQuery en tus proyectos de datos. ¡Prepárate para llevar tus habilidades de análisis al siguiente nivel!

Made with GAMMA

Hoja de Ruta: Preparación, Carga y Análisis de Datos en BigQuery

Para dominar BigQuery, es fundamental comprender el ciclo de vida completo de los datos: desde su origen y preparación, pasando por su ingesta en la plataforma, hasta su transformación en insights valiosos mediante potentes consultas SQL. Esta sección establece nuestra hoja de ruta, desglosando los dos capítulos clave que abordaremos: la preparación y carga de datos, y el análisis avanzado en BigQuery. Cada paso es crucial para asegurar la calidad y eficiencia de tus procesos analíticos.

Capítulo 3: Preparación y Carga de Datos

Nos centraremos en cómo alistar tus datos para BigQuery. Esto incluye las mejores prácticas para formatear archivos CSV, las diversas opciones de carga disponibles (consola, bq tool, API) y una guía detallada, paso a paso, para subir tus primeros archivos a BigQuery, creando datasets y tablas desde cero. Comprender este proceso es la base para cualquier análisis futuro.

- Preparación de archivos CSV: requisitos y buenas prácticas.
- Opciones de carga de datos en BigQuery.
- Proceso guiado de carga de datos paso a paso.

Capítulo 4: Análisis de Datos con BigQuery

Una vez los datos estén en BigQuery, exploraremos cómo consultarlos y analizarlos. Cubriremos desde las consultas SQL básicas hasta técnicas más avanzadas como JOINs y subconsultas. También aprenderemos sobre funciones de agregación y, fundamentalmente, estrategias para optimizar tus consultas, lo que es vital para gestionar costes y rendimiento en un entorno de big data.

- Fundamentos de las consultas SQL: SELECT, FROM, WHERE.
- Técnicas avanzadas: JOINs y subconsultas.
- Funciones de agregación y optimización de consultas.

Made with GAMMA

Capítulo 3: Preparación de Archivos CSV para BigQuery

La calidad de tus datos es la base de cualquier análisis exitoso. Antes de cargar cualquier información en BigQuery, especialmente desde archivos CSV (Comma Separated Values), es crucial asegurarse de que cumplen con ciertos requisitos y seguir una serie de buenas prácticas. Un archivo CSV bien preparado facilitará una carga fluida y evitará errores comunes que pueden consumir tiempo y recursos valiosos. Este es el primer paso crítico en nuestro viaje de datos.

Requisitos Fundamentales

- **Codificación UTF-8:** Es la codificación de caracteres recomendada para evitar problemas con caracteres especiales o acentos.
- **Delimitador Consistente:** Generalmente, la coma (`,`) es el delimitador estándar, pero BigQuery admite otros como el punto y coma (`;`) o la barra vertical (`|`). Asegúrate de que sea uniforme en todo el archivo.
- **Encabezados Claros y Únicos:** La primera fila del CSV debe contener los nombres de las columnas. Estos nombres deben ser únicos, descriptivos y preferiblemente sin espacios ni caracteres especiales (puedes usar guiones bajos).
- **Tipos de Datos Consistentes:** Cada columna debe contener datos de un solo tipo (por ejemplo, todos números, todas cadenas de texto, todas fechas). Las inconsistencias causarán errores en la carga.
- **Ausencia de Caracteres no Válidos:** Evita saltos de línea dentro de campos, comillas mal cerradas o caracteres invisibles que puedan corromper la estructura.

Buenas Prácticas Adicionales

Normalización de Datos

Asegúrate de que los formatos de fecha, hora y números sean consistentes. Por ejemplo, `YYYY-MM-DD` para fechas.

Manejo de Valores Nulos

Representa los valores nulos de forma explícita (por ejemplo, dejándolos en blanco) en lugar de usar cadenas como `"N/A"` o `"-"`.

Tamaño de Archivo

Para archivos muy grandes, considera dividirlos en partes más pequeñas. BigQuery puede gestionar archivos enormes, pero para la depuración inicial, los archivos más pequeños son más manejables.

Validación Pre-Carga

Utiliza herramientas de hoja de cálculo o scripts sencillos para pre-validar tus CSV antes de intentar cargarlos.

Made with GAMMA

Opciones de Carga de Datos en BigQuery

BigQuery ofrece flexibilidad a la hora de ingerir datos, adaptándose a diferentes volúmenes, frecuencias y niveles de automatización. Comprender las diversas opciones de carga es clave para elegir la estrategia más eficiente y rentable para tus necesidades. Cada método tiene sus propias ventajas y se adapta a distintos escenarios de uso, desde cargas manuales y puntuales hasta flujos de trabajo automatizados a gran escala.

Consola de Google Cloud

La interfaz web de Google Cloud es el método más sencillo y visual para cargar datos, especialmente útil para archivos pequeños y cargas manuales. Permite definir esquemas, previsualizar datos y gestionar el proceso de carga sin necesidad de código. Es ideal para usuarios que se inician en BigQuery o para tareas ad-hoc.

- Interfaz gráfica e intuitiva.
- Ideal para cargas interactivas y pequeñas.
- Ofrece validación y previsualización.

Herramienta de Línea de Comandos (bq tool)

La herramienta `bq` es una utilidad de línea de comandos de Python que interactúa con BigQuery. Es perfecta para automatizar cargas mediante scripts y para gestionar tareas repetitivas. Permite una mayor personalización y control sobre el proceso de carga que la consola web.

- Automatización vía scripts.
- Mayor control y personalización.
- Eficiente para volúmenes medianos a grandes.

APIs (Python, Java, Node.js, etc.)

Las APIs de BigQuery, disponibles en múltiples lenguajes de programación, son la opción más potente y flexible para la integración con aplicaciones y la construcción de pipelines de datos complejos y a gran escala. Permiten el streaming de datos, cargas asíncronas y control total sobre el proceso.

- Máxima flexibilidad y personalización.
- Ideal para integración con aplicaciones y ETLs.
- Soporte para streaming de datos en tiempo real.

La elección del método dependerá de tus necesidades específicas: la consola para la exploración y tareas sencillas, la herramienta `bq` para la automatización en entornos controlados, y las APIs para la integración profunda y soluciones a escala empresarial. Para nuestro proceso guiado, utilizaremos principalmente la Consola de Google Cloud por su facilidad de uso y accesibilidad.

Made with GAMMA

Proceso Guiado: Creación del Dataset en BigQuery

Un dataset en BigQuery es un contenedor lógico para tus tablas y vistas. Es similar a una base de datos en otros sistemas de gestión de bases de datos. Antes de poder cargar cualquier dato, es fundamental crear un dataset donde residirán nuestras tablas. Este paso es el punto de partida organizativo para todos tus proyectos en BigQuery.

Paso 1: Acceder a la Consola de BigQuery

Navega a la **Consola de Google Cloud**. Asegúrate de que estás en el proyecto de GCP correcto. En el menú de navegación izquierdo, busca "BigQuery" o escribe "BigQuery" en la barra de búsqueda superior y selecciónalo.

Paso 2: Crear un Nuevo Dataset

En el panel izquierdo, bajo el nombre de tu proyecto, verás una opción para **"Crear conjunto de datos"** (o un icono de tres puntos verticales junto al nombre de tu proyecto para más opciones). Haz clic en esta opción para iniciar el proceso de creación.

Paso 3: Configurar los Detalles del Dataset

Se abrirá una ventana donde deberás configurar los parámetros de tu dataset:

- **ID del conjunto de datos:** Asigna un nombre único y descriptivo para tu dataset (por ejemplo, `mi_primer_dataset`). Este ID no se puede cambiar después de la creación.
- **Ubicación de los datos:** Selecciona una región o multirregión donde se almacenarán tus datos. Es importante elegir una ubicación cercana a tus usuarios o a otras fuentes de datos para minimizar la latencia. Para ejercicios, puedes usar una multirregión como `US (multiple regions in United States)` o `EU (multiple regions in European Union)`.
- **Configuración avanzada:** Aquí puedes establecer la fecha de vencimiento predeterminada para las tablas (si quieres que expiren automáticamente) o configurar claves de encriptación gestionadas por el cliente.

Una vez configurado, haz clic en **"Crear conjunto de datos"**.

Paso 4: Verificación del Dataset

Tu nuevo dataset aparecerá listado bajo tu proyecto en el panel izquierdo de la consola de BigQuery. Al hacer clic en él, podrás ver sus propiedades y, eventualmente, las tablas que contenga. ¡Felicidades, has creado tu primer contenedor de datos en BigQuery!

Made with GAMMA

Proceso Guiado: Carga de la Primera Tabla desde CSV

Una vez que tenemos nuestro dataset listo, el siguiente paso es cargar los datos. Para este ejemplo, utilizaremos un archivo CSV. BigQuery facilita la carga de datos desde fuentes locales, Google Cloud Storage, Google Drive o incluso desde URL públicas. Nos enfocaremos en la carga directa desde tu ordenador a través de la consola, un método común para iniciar.

Paso 1: Seleccionar el Dataset y la Opción de Creación

En la consola de BigQuery, haz clic en el dataset que acabas de crear (por ejemplo, `mi_primer_dataset`). Verás la opción **"Crear tabla"** o un icono de **`+`** al lado del nombre del dataset. Haz clic en él para comenzar el proceso de carga.

Paso 2: Configurar los Detalles de la Tabla

En la ventana "Crear tabla", deberás especificar los siguientes detalles:

- **Fuente:**
  - **Crear tabla desde:** Selecciona `Subir` para cargar desde tu máquina local.
  - **Selecciona archivo:** Haz clic en "Examinar" y selecciona tu archivo CSV (por ejemplo, `productos.csv`).
  - **Formato de archivo:** Asegúrate de que esté configurado como `CSV`.
- **Destino:**
  - **Nombre del proyecto:** Ya debería estar seleccionado tu proyecto actual.
  - **Nombre del conjunto de datos:** Tu dataset recién creado debe aparecer automáticamente.
  - **Nombre de la tabla:** Dale un nombre descriptivo a tu tabla (por ejemplo, `productos`).

Paso 3: Definir el Esquema y Opciones Avanzadas

1	2
Esquema **Detección automática:** BigQuery puede detectar el esquema y los tipos de datos automáticamente si tu CSV es limpio. Activa la casilla **"Detección automática de esquema"** y **"Fila de encabezado"** si tu archivo CSV tiene encabezados. **Definir manualmente:** Para mayor control, puedes añadir campos manualmente, especificando el nombre de la columna y su tipo de dato (STRING, INTEGER, FLOAT, BOOLEAN, DATE, etc.). Esto es útil si la detección automática falla o si necesitas anular tipos específicos.	**Opciones Avanzadas** • **Delimitador de campo:** Por defecto es coma (`,`). Si tu CSV usa otro (punto y coma `;`), cámbialo aquí. • **Ignorar filas de encabezado:** Si tu archivo tiene encabezados, asegúrate de que este número sea `1` para que BigQuery no los interprete como datos. • **Comillas:** El carácter de comilla por defecto es `"`. Si tus datos contienen comillas y no son parte de un campo, asegúrate de que este valor sea correcto.

Revisa todas las configuraciones cuidadosamente y, cuando estés listo, haz clic en **"Crear tabla"**. BigQuery procesará tu archivo y cargará los datos. Puedes monitorear el estado de la carga en la sección "Historial de trabajos". ¡En unos instantes, tu primera tabla estará disponible para consultas!

Made with GAMMA

Proceso Guiado: Carga de las Tablas Restantes

El proceso de carga de las tablas restantes (por ejemplo, `clientes.csv` y `pedidos.csv`) sigue la misma lógica que la carga de la primera tabla. La clave aquí es la consistencia y la organización. Al repetir los pasos anteriores para cada archivo, construirás un conjunto de datos completo y listo para el análisis.

01

Repetición del Proceso

Para cada archivo CSV adicional (en nuestro ejemplo, `clientes.csv` y `pedidos.csv`), repite los pasos descritos en la tarjeta anterior:

- **Seleccionar el Dataset:** Asegúrate de que estás en el mismo dataset (`mi_primer_dataset`) donde cargaste la primera tabla.
- **Hacer clic en "Crear tabla":** Inicia un nuevo proceso de carga para cada archivo.

02

Configuración de cada Tabla

Asegúrate de:

- **Seleccionar el archivo CSV correcto:** Elige `clientes.csv` para la tabla `clientes` y `pedidos.csv` para la tabla `pedidos`.
- **Asignar un nombre de tabla único y descriptivo:** Utiliza nombres que reflejen el contenido, como `clientes` y `pedidos`.
- **Verificar el esquema:** Confirma que la detección automática de esquema funciona correctamente para cada nuevo archivo. Si es necesario, ajusta manualmente los tipos de datos para garantizar la precisión. Por ejemplo, las columnas de identificación de cliente o producto deben ser `STRING` o `INTEGER` según corresponda, y las fechas en la tabla de pedidos deben ser `DATE` o `TIMESTAMP`.

03

Verificación Final

Una vez que todas las cargas se hayan completado, expande tu dataset en el panel izquierdo de la consola de BigQuery. Deberías ver las tres tablas: `productos`, `clientes` y `pedidos`. Haz clic en cada tabla para explorar su esquema y previsualizar los datos. Esto confirmará que los datos se han cargado correctamente y que los tipos de datos han sido inferidos (o asignados) de forma adecuada.

Con todas tus tablas cargadas, estás listo para el siguiente capítulo: ¡analizar tus datos con el poder de SQL en BigQuery! La base está puesta para explorar relaciones y extraer insights valiosos.

Made with GAMMA

Capítulo 4: Consultas Básicas en BigQuery (SELECT, FROM, WHERE)

Una vez que tus datos residen en BigQuery, la magia comienza con las consultas SQL. El lenguaje SQL (Structured Query Language) es el estándar para interactuar con bases de datos relacionales, y BigQuery lo utiliza para permitirte extraer, manipular y analizar tus datos. Empezaremos con los pilares de cualquier consulta: `SELECT`, `FROM` y `WHERE`.

SELECT: Qué Columnas Quieres Ver

La cláusula `SELECT` es el corazón de tu consulta; especifica qué columnas de tu tabla deseas recuperar. Puedes seleccionar columnas específicas o usar un asterisco `*` para obtener todas las columnas.

```
-- Seleccionar todas las columnas de la tabla 'productos'
SELECT *
FROM `mi_proyecto.mi_primer_dataset.productos`;

-- Seleccionar solo el nombre y el precio de los productos
SELECT nombre_producto, precio
FROM `mi_proyecto.mi_primer_dataset.productos`;
```

Nota sobre la ruta de tabla: En BigQuery, la ruta completa de una tabla sigue el formato `\`proyecto.dataset.tabla\``. Es buena práctica usar comillas invertidas (`` ` `` `) para evitar problemas con nombres que contengan caracteres especiales o palabras reservadas.

FROM: De Dónde Obtener los Datos

La cláusula `FROM` indica la tabla (o tablas) de la que BigQuery debe extraer los datos. Es esencial para especificar la fuente de tu consulta.

```
-- Obtener datos de la tabla 'clientes'
SELECT nombre, email
FROM `mi_proyecto.mi_primer_dataset.clientes`;
```

WHERE: Filtrar tus Resultados

La cláusula `WHERE` te permite filtrar filas basándose en condiciones específicas. Solo las filas que cumplen la condición se incluirán en el resultado. Aquí es donde aplicas tus criterios para refinar tus análisis.

```
-- Seleccionar productos con un precio mayor a 50
SELECT nombre_producto, precio
FROM `mi_proyecto.mi_primer_dataset.productos`
WHERE precio > 50;

-- Seleccionar pedidos con estado 'pendiente'
SELECT id_pedido, fecha_pedido
FROM `mi_proyecto.mi_primer_dataset.pedidos`
WHERE estado = 'pendiente';
```

Puedes combinar múltiples condiciones `WHERE` usando operadores lógicos como `AND`, `OR` y `NOT` para crear filtros más complejos.

Made with GAMMA

Manejo de Múltiples Tablas: JOINs y Subconsultas

En el mundo real, los datos rara vez residen en una única tabla. Las bases de datos se diseñan con múltiples tablas relacionadas para evitar la redundancia y mantener la integridad. BigQuery, al igual que otros sistemas SQL, te permite combinar información de varias tablas utilizando `JOINs` y subconsultas, abriendo la puerta a análisis mucho más complejos y ricos.

Tablas Separadas

Tienes datos de clientes, productos y pedidos en tablas distintas. Cada tabla tiene su propia información única pero también comparte claves comunes para relacionarse (ej., `id_cliente`, `id_producto`).

JOINs

Los `JOINs` te permiten combinar filas de dos o más tablas basándose en una columna relacionada entre ellas. Los tipos más comunes son `INNER JOIN`, `LEFT JOIN`, `RIGHT JOIN` y `FULL OUTER JOIN`.

Subconsultas

Una subconsulta (o consulta anidada) es una consulta SQL dentro de otra consulta SQL. Se utilizan para construir condiciones complejas que dependen de un resultado de otra consulta, o para crear "tablas" temporales para un procesamiento posterior.

INNER JOIN: Combinando Pedidos y Clientes

Un `INNER JOIN` devuelve solo las filas que tienen coincidencias en ambas tablas. Por ejemplo, para ver los nombres de los clientes junto con sus pedidos:

```
SELECT
  c.nombre_cliente,
  c.email,
  p.id_pedido,
  p.fecha_pedido,
  p.total
FROM
  `mi_proyecto.mi_primer_dataset.clientes` AS c
INNER JOIN
  `mi_proyecto.mi_primer_dataset.pedidos` AS p
ON
  c.id_cliente = p.id_cliente
WHERE
  p.fecha_pedido >= '2023-01-01';
```

LEFT JOIN: Incluyendo Clientes sin Pedidos

Un `LEFT JOIN` devuelve todas las filas de la tabla de la izquierda, y las filas coincidentes de la tabla de la derecha. Si no hay coincidencia, devuelve `NULL` para las columnas de la tabla de la derecha. Útil para identificar clientes que aún no han realizado ningún pedido.

```
SELECT
  c.nombre_cliente,
  COUNT(p.id_pedido) AS numero_pedidos
FROM
  `mi_proyecto.mi_primer_dataset.clientes` AS c
LEFT JOIN
  `mi_proyecto.mi_primer_dataset.pedidos` AS p
ON
  c.id_cliente = p.id_cliente
GROUP BY
  c.nombre_cliente;
```

Subconsultas: Clientes con Pedidos de Alto Valor

Una subconsulta puede usarse, por ejemplo, para encontrar a los clientes que han realizado pedidos con un total superior a cierto valor.

```
SELECT
  nombre_cliente,
  email
FROM
  `mi_proyecto.mi_primer_dataset.clientes`
WHERE
  id_cliente IN (
    SELECT
      id_cliente
    FROM
      `mi_proyecto.mi_primer_dataset.pedidos`
    WHERE
      total > 200
  );
```

La combinación de `JOINs` y subconsultas te permite conectar y filtrar datos de formas muy potentes, desbloqueando análisis complejos que van más allá de lo que se podría lograr con una sola tabla.

Made with GAMMA