Formación SQL 360°

Session 8 : GCP

Facilitador: Flavio Bevilacqua

https://www.linkedin.com/flabevy

Temario de Clase:

- OLTP VS OLAP
- Modelo Estrella vs Copo de Nieve
- GCP
- Big Query
- Consideraciones
- Integridad Referencial

OLTP VS OLAP

Procesamiento de la Información

- Actualmente, encontramos dos sistemas de procesamiento vigentes, denominados OLAP y OLTP.

- Ambos sistemas guardan determinadas diferencias a los fines prácticos y funcionales.

- Sera importante considerar desde la premisa sobre la cual toda porción de información debe procesarse para ser analizable, por lo que su uso depende de un correcto tratamiento.

SISTEMAS OLTP

- **OLTP** es sinónimo de **online transaction processing**, lo que significa procesamiento de transacciones en línea permitiendo la ejecución de varias operaciones simultaneas en la base de datos.
- Muchos actos habituales involucran OLTP, por ejemplo, ir al cajero automático a retirar dinero, terminales de punto de venta (POS) vinculadas al software de gestión de inventario, compras en línea. Motivo por el cual, estos sistemas permiten el flujo lineal de la operación transaccional/operativa del negocio.

SISTEMAS OLAP

- **OLAP** es sinónimo de **procesamiento analítico en línea**, cuyo objetivo es agilizar la consulta y explotación de la informacion.
- Las bases OLAP se usan para determinar a lo largo del tiempo por ejemplo cuál es el producto más vendido de una empresa, que trimestre del año es más rentable o quien es el mejor cliente.
- Usualmente las empresas trasladan sus datos históricos del ambiente de producción OLTP a un ambiente OLAP, para acumular información, este traslado de datos puede implicar la transformación de los dato.

OLTP VS OLAP

La separación es necesaria porque las necesidades de acceso a los datos son opuestas: mientras uno busca integridad y velocidad en la escritura, el otro busca velocidad en la lectura y agregación. Mezclarlos degrada el rendimiento de ambos.

Característica	OLTP (Transaccional)	OLAP (Analítico)
Propósito	Gestión de operaciones diarias.	Toma de decisiones estratégicas.
Escritura	Frecuente (INSERT, UPDATE, DELETE).	Rara (Carga por procesos ETL).
Lectura	Consultas simples (PKs, registros únicos).	Consultas complejas (Agregaciones, rangos).
Normalización	Alta (para evitar redundancia).	Baja/Desnormalizado (Star/Snowflake).
Performance	Enfocada en baja latencia.	Enfocada en alto rendimiento de consulta.

MODELOS

MODELO ESTRELLA

Es una forma de modelar los datos que consiste en una tabla de hechos en el centro para el hecho objeto de análisis y una o varias tablas de dimensión por cada dimensión de análisis que participa de la descripción de ese hecho.

Transaccional: contienen datos medibles, cuantitativos, relacionados a la transacción del negocio.

Dimensiones: son agrupamientos lógicos de atributos y ofrecen información adicional sobre los hechos.

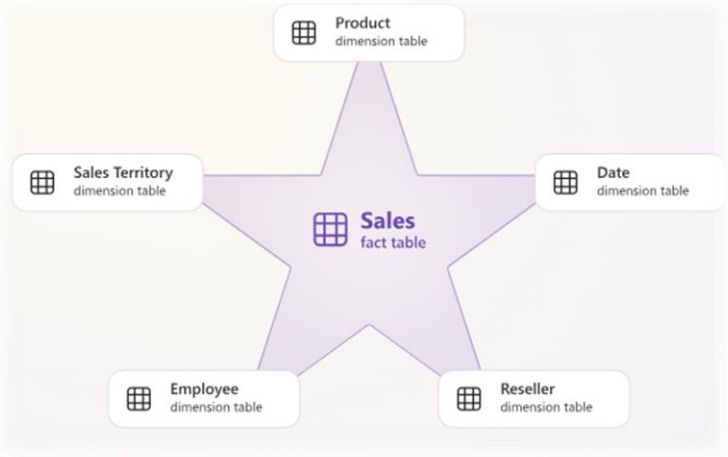

MODELO COPO DE NIEVE

En lugar de tener dimensiones con todos sus atributos en una sola tabla, los atributos se descomponen en múltiples tablas relacionadas entre sí mediante claves foráneas.

Normalización: Reduce la redundancia de datos al separar atributos jerárquicos o de baja cardinalidad en tablas secundarias, optimizando el espacio de almacenamiento.

Estructura: Las tablas de dimensiones se extienden como ramas de un árbol (o copo de nieve) a partir de la tabla de hechos, creando niveles de profundidad adicionales.

Complejidad: Al requerir más Joins para consolidar la información, aumenta la complejidad de las consultas SQL, pero mejora la integridad y el mantenimiento de los datos maestros.

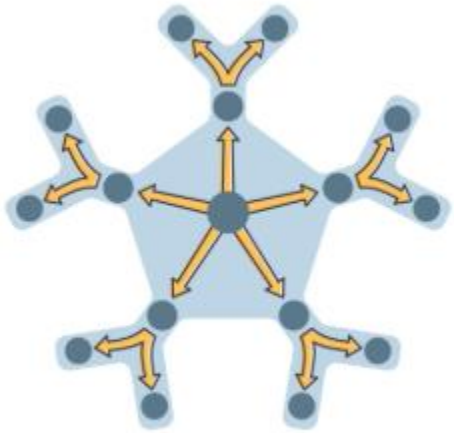

SNOWFLAKE SCHEMA

GCP

GCP

- Es una suite de servicios de computación en la nube de Google que ofrece infraestructura segura y escalable (servidores, almacenamiento, IA, análisis de datos) sobre la misma tecnología que utiliza Google internamente.
- Permite a empresas crear, implementar y gestionar aplicaciones, bases de datos y herramientas analíticas mediante pago por uso

Características clave de GCP:

- **Servicios Principales:** Incluye cómputo (Compute Engine), almacenamiento (Cloud Storage), redes (VPC) y bases de datos (Cloud SQL, AlloyDB).
- **IA y Machine Learning:** Destaca por sus herramientas avanzadas como Vertex AI y Gemini Code Assist para crear aplicaciones de inteligencia artificial.
- **Contenedores y Serverless:** Facilita la gestión de aplicaciones con Google Kubernetes Engine y Cloud Run.
- **Infraestructura Global:** Funciona sobre la red global de alta velocidad y segura de Google.

BIG QUERY

BIG QUERY

- BigQuery es el Data Warehouse moderno y serverless de Google Cloud, diseñado específicamente para realizar análisis de datos a escala de petabytes con una velocidad vertiginosa. A diferencia de SQL Server o bases de datos relacionales tradicionales, BigQuery no requiere que configures servidores, administres discos, ni te preocupes por el hardware. Tú solo escribes tu consulta SQL y Google se encarga de movilizar cientos de procesadores en paralelo para devolverte el resultado en segundos. Es, en esencia, un motor de análisis de datos como servicio.

“ BigQuery es como tener un 'supercomputador' a tu disposición que solo vive el tiempo que tarda tu consulta SQL en ejecutarse. Cuando la consulta termina, la computadora desaparece y solo pagas por los segundos que trabajó "

FUNDAMENTOS PRINCIPALES

- **Arquitectura Serverless:** No requiere gestión de infraestructura (servidores, discos o mantenimiento). Google escala los recursos automáticamente según la consulta.

- **Separación de Computación y Almacenamiento:** Permite escalar ambos de forma independiente, optimizando costos y rendimiento masivo.

- **Motor de SQL Estándar:** Utiliza SQL compatible con ANSI, facilitando la transición desde bases de datos relacionales tradicionales (como SQL Server).

- **Alta Disponibilidad**: Almacenamiento distribuido, cifrado y redundante por defecto.

SERVICIOS Y CAPACIDADES

- **Análisis Multicloud (BigQuery Omni):** Permite consultar datos almacenados en AWS o Azure sin moverlos.
- **Machine Learning (BigQuery ML):** Crea y ejecuta modelos de ML directamente con consultas SQL sin necesidad de exportar datos.
- **Geospatial Analysis**: Soporte nativo para funciones de tipo GEOGRAPHY para análisis geoespacial complejo.
- **BI Engine:** Un servicio de análisis en memoria (in-memory) que acelera los paneles de control de Looker/Tableau.

CONSIDERACIONES

TABLA DE HECHOS (Fact)

- Contienen datos mínimos imprescindibles que registran un hecho.
- Contienen datos cuantitativos que se utilizan para hacer cálculos (monto, cantidad, etc)
- Generalmente almacenan códigos que luego serán relacionados con las tablas de búsqueda.
- Es la tabla principal del modelo y su contexto es el motor del negocio.

Tabla de pedidos

Id	Fecha	Vendedor_id	Producto_id	Cliente_ID	Monto	Cantidad
21	2/1/2017	1	21	111	$25.000	2
23	2/1/2017	2	23	123	$12.000	1
45	3/1/2017	2	46	4545	$19.000	1

TABLAS DIMENSIONALES (Dim)

- En el modelo estrella, cada una de estas tablas conforma una dimensión.
- Almacenan atributos o características de un elemento.
- Se utilizan generalmente para parametrizar consultas
- Contiene información que puede “recuperarse” a partir de relaciones.

Tabla de productos

Código	Nombre	Stock	Almacén	Tipo	Rubro
21	Notebook HP BR456	26	1	PC Portátil	Electrónica
23	TV Samsung NG 2093	74	1	Televisor	Electrónica
45	Sillón 345	2	2	Sillón	Mueble

INTEGRIDAD REFERENCIAL

CLAVES PRIMARIAS Y FORANEAS

En BigQuery, las claves primarias (PK) y foráneas (FK) son puramente **CONCEPTUALES.**

En efecto, puedes declararlas en tu modelo de datos o documentación, pero BigQuery no las aplica físicamente. **Esto implica que no hay restricción de integridad**. Si intentas insertar un ID Producto en Transacciones que no existe en Productos, BigQuery no te dará un error. El motor no usa las PKs para hacer JOINs más rápidos como lo haría un motor OLTP.

- **En OLTP (SQL Server):** El motor actúa como un "guardia de seguridad". Si alguien intenta romper la integridad referencial, el motor lo detiene.
- **En OLAP (BigQuery):** El motor actúa como un "procesador masivo". La integridad se valida **antes** de que el dato entre (en el proceso de limpieza o transformación del Data Pipeline). Una vez que el dato está en BigQuery, se asume que es "bueno".

CONSIDERACIONES

- La carga del control pasa al ETL: Si quieres evitar datos huérfanos, debes implementar la lógica de validación en tu pipeline (ej. en Dataflow, dbt o Apache Airflow) antes de que el dato toque BigQuery.

- Modelado Desnormalizado: Como no hay PK/FK que mantener, BigQuery prefiere tablas anchas.

- Performance basada en Columnas: En SQL Server, un JOIN entre PK y FK es eficiente gracias a los índices. En BigQuery, el rendimiento viene de leer solo las columnas necesarias.

Live Coding!

Gracias